

Relatório de Tratamento de Dados e Regra de Cálculo de Status

Desafio Final — Desenvolvimento de Soluções RPA com Python
PUC Minas — Prof. Leandro Lessa | Autor: Pedro | Setembro de 2026

1. Bases de dados utilizadas

A automação consome três bases fictícias, extraídas de sistemas diferentes: `gestores_projetos.csv` (relação de projetos e gestor responsável), `status_projetos.csv` (andamento, prazos e orçamento) e `rh_treinamentos.csv` (treinamentos obrigatórios por área). Nenhuma das três estava pronta para uso direto.

2. Inconsistências encontradas e tratamento aplicado

- **Texto e categorias:** — espaços extras, variações de caixa e acentuação em nomes, áreas e categorias de texto (ex.: "ti", "T.I", "Ti "). Tratado com normalização de espaços, remoção de acentos e padronização de caixa (nomes em Title Case; códigos, IDs e categorias em UPPER) para evitar agrupamentos incorretos.
- **Chave de integração:** — a coluna `codigo_projeto`, chave entre `gestores_projetos` e `status_projetos`, aparecia com espaços e caixa inconsistentes entre as duas bases. A coluna `area`, chave entre os dados de projeto e `rh_treinamentos`, tinha o mesmo problema. Ambas foram padronizadas (`strip + upper`) antes de qualquer merge.
- **Datas:** — datas vinham em formatos mistos entre linhas e colunas. Convertidas com `pd.to_datetime(format="mixed", errors="coerce")`, mantendo o tipo `datetime` (nunca convertido para texto antes da hora de exibir), pois o cálculo de status e de duração depende de comparação real entre datas.
- **Valores ausentes:** — `data_conclusao` ausente foi tratada como informação (projeto ainda não concluído), não como erro, e não é preenchida nem descartada. Já em `percentual_concluido` e `valor_orcado`, valores ausentes ou não numéricos foram convertidos para NaN via `pd.to_numeric(errors="coerce")` e ignorados (`skipna`) nos indicadores agregados, em vez de zerados — evitando distorcer médias e somas.
- **Duplicidade:** — registros duplicados foram removidos de forma genérica: em `gestores_projetos` e `rh_treinamentos` por linha inteiramente repetida; em `status_projetos` por `codigo_projeto` (mantendo a primeira ocorrência), já que o projeto deve ser único ali.

3. Regra de cálculo do status dos projetos

Não existe coluna de status pronta — ela é deduzida comparando `data_inicio`, `data_prevista_fim` e `data_conclusao`, de forma genérica (funciona para qualquer execução, sem valores fixos):

- **Concluído dentro do prazo:** `data_conclusao` preenchida e $\leq$ `data_prevista_fim`.
- **Concluído com atraso:** `data_conclusao` preenchida e $>$ `data_prevista_fim`.
- **Atrasado:** sem `data_conclusao` e `data_prevista_fim` já passou da data atual.
- **Em andamento:** sem `data_conclusao` e `data_prevista_fim` ainda não chegou.

A partir dessa classificação são calculados, por gestor: quantidade de projetos em cada situação, percentual médio de execução (só dos projetos não concluídos), tempo médio de conclusão em dias (só dos concluídos) e valor total orçado. Os indicadores de treinamento (pendentes, vencidos e % de conformidade por área) seguem a mesma lógica: vencido é deduzido comparando `data_limite` com a data atual, não por rótulo de texto.